

Bedienungsanleitung – InhaltsVZ-Tool

Das InhaltsVZ-Tool ermöglicht es, Datensätze mit digitalisierten Inhaltsverzeichnissen (ToC = Table of Contents) anhand von frei festlegbaren Stichworten zu selektieren. Den einzelnen Stichworten können dabei unterschiedliche Gewichtungen zugewiesen werden.

Das Tool wird vom Deutschen Buch- und Schriftmuseum (DBSM) auf GitHub bereitgestellt:
<https://github.com/buchmuseum/InhaltVZ-Tool>

Es wird empfohlen, das Repository bzw. den Programmcode auf den eigenen Rechner herunterzuladen, damit das Tool lokal ausgeführt und an die eigenen Anforderungen angepasst werden kann.

Inhalt

Bedienungsanleitung – InhaltsVZ-Tool.....	1
1. Programm starten	2
2. Aufbau und Bedienung des InhaltsVZ-Tools.....	5
2.1 Eingabefelder.....	5
2.2 Auswahlmöglichkeiten	5
2.3 Verarbeitung starten	6
3. Harvesting.....	7
3.1 Eingabe	7
3.2 Verarbeitung starten	7
4. Keyword-Analyse.....	9
4.1 Eingabe	9
4.2 Verarbeitung starten	9
5. SRU-Schnittstelle	11
5.1 Auswahlmöglichkeiten	11
5.2 Verarbeitung starten	11
6. Statusanzeige.....	13
7. Verarbeitung abbrechen	13
8. Ergebnisse.....	14
9. Dateien	14
idn.txt	14
stichwort.xlsx.....	15
10. Logdatei	17

1. Programm starten


Das InhaltsVZ-Tool wird über die Datei `main.py` gestartet.

Wichtig vor dem ersten Start:


Bitte vergewissern Sie sich, dass sich im Ordner `data/` die beiden benötigten Dateien `idn.txt` und `stichwort.xlsx` befinden. Weitere Information unter Punkt 8. Dateien

📁 .ipynb_checkpoints	30.07.2026 06:46	Dateiordner	
📁 config	23.07.2026 16:25	Dateiordner	
📁 core	20.07.2026 07:07	Dateiordner	
📁 data	12.08.2026 11:27	Dateiordner	
📁 gui	20.07.2026 07:07	Dateiordner	
📁 infrastructure	20.07.2026 07:07	Dateiordner	
📁 logs	20.07.2026 07:07	Dateiordner	
📄 .gitignore	20.07.2026 07:36	Git Ignore-Quelld...	1 KB
📄 config.ini	09.07.2026 09:11	Konfigurationsein...	1 KB
📄 main.py	09.07.2026 14:08	Python-Quelldatei	1 KB
📄 README.md	12.08.2026 10:11	MD-Datei	3 KB
📄 requirements.txt	09.07.2026 09:10	Textdokument	1 KB

Öffnen Sie zunächst **Jupyter**, die **Anaconda-Umgebung** oder eine andere Umgebung, in der eine **Python-Installation** zur Verfügung steht.



```
1 from infrastructure.logging_config import setup_logging
2
3 import tkinter as tk
4
5 from gui.main_window import MainWindow
6
7
8
9 def main():
10
11     setup_logging()
12
13
14     root = tk.Tk()
15
16
17     app = MainWindow(
18         root
19     )
20
21
22     root.mainloop()
23
24
25
26 if __name__ == "__main__":
27     main()
28
```




Öffnen Sie anschließend ein **Terminal**.

Wechseln Sie im Terminal in den Ordner, in dem sich die Datei `main.py` befindet.

Anschließend starten Sie das Programm mit folgendem Befehl:


```
python main.py
```

Hinweis: Falls nicht automatisch der korrekte Ordner geöffnet ist, können Sie über den Befehl `cd` Ordnername in den entsprechenden Programmordner wechseln.)



Bestätigen Sie den Befehl mit **Enter**.

Nach dem Start öffnet sich die Benutzeroberfläche des InhaltsVZ-Tools in einem eigenen Fenster. Eventuell öffnet sich die hinter der aktuellen Anwendung. Achten Sie bitte unten in der Taskleiste auf das



2. Aufbau und Bedienung des InhaltsVZ-Tools

Das InhaltsVZ-Tool besteht aus drei unabhängig voneinander bedienbaren Bereichen:

- **Harvesting**
- **Keyword-Analyse**
- **SRU-Schnittstelle**

Die drei Bereiche können **unabhängig voneinander** verwendet werden. Je nach gewünschtem Arbeitsschritt kann daher nur der benötigte Bereich ausgeführt werden.


Die Bedienung folgt in allen drei Bereichen grundsätzlich demselben Prinzip:

Eingabefelder → Auswahlmöglichkeiten → Verarbeitung starten → Statusmeldung

2.1 Eingabefelder


In den Eingabefeldern werden die für die Verarbeitung benötigten Angaben eingetragen.

Je nach Bereich können dies beispielsweise Datumsangaben oder eine Mindestgewichtung sein.



Startdatum (YYYY-MM-DD)


Enddatum (YYYY-MM-DD)



2.2 Auswahlmöglichkeiten

Über Auswahlfelder können zusätzliche Einstellungen für die Verarbeitung festgelegt werden.

Ein aktiviertes Kontrollkästchen wird bei der Verarbeitung berücksichtigt. Mehrere Auswahlmöglichkeiten können gleichzeitig aktiviert werden.



☐ Titel
☐ Zusatztitel
☐ Autor
☐ Verlag

2.3 Verarbeitung starten

Nachdem die erforderlichen Eingaben vorgenommen und gegebenenfalls Auswahlmöglichkeiten festgelegt wurden, wird die Verarbeitung über die entsprechende Schaltfläche gestartet.

Harvest starten

Analyse starten

SRU Update starten

Nach dem Start arbeitet das Programm selbstständig weiter. Der aktuelle Stand wird im Statusfeld angezeigt.

STOP

3. Harvesting


Mit dem Bereich **Harvesting** werden die für die weitere Verarbeitung benötigten IDNs aus dem festgelegten Zeitraum über **die OAI-Schnittstelle** ermittelt.

Über die OAI-Schnittstelle werden alle neuen Datensätze mit digitalisiertem Inhaltsverzeichnis, aber auch aktuell bearbeitete Datensätze ausgeliefert. Deshalb hat das Tool eine Dubletten-Prüfung. Hier werden die IDNs von bereits genutzten Datensätzen aus der aktuellen Bearbeitung ausgeschlossen.

Um die Menge der zu verarbeitenden Datensätze nicht zu groß werden zu lassen, empfiehlt sich zunächst mit kleinen Zeiträumen zu arbeiten

3.1 Eingabe

Für das Harvesting werden ein **Startdatum** und ein **Enddatum** eingegeben.

The image shows a web form with two input fields. The first field is labeled 'Startdatum (YYYY-MM-DD)' and the second field is labeled 'Enddatum (YYYY-MM-DD)'. Both fields are empty and have a light gray border.

Die Datumsangaben müssen im Format `YYYY-MM-DD` eingegeben werden.

Beispiel:


2026-08-01

bis

2026-08-31


3.2 Verarbeitung starten

Nach Eingabe des Zeitraums wird die Verarbeitung über „**Harvest starten**“ gestartet.


The image shows a button with the text 'Harvest starten' in a blue font. The button has a light gray background and a thin border.

Das Programm ermittelt die entsprechenden Datensätze und speichert die gefundenen IDNs.

Anschließend kann ein Abgleich (Dublettenüberprüfung) mit der bereits vorhandenen `idn.txt` durchgeführt werden. Bereits bekannte IDNs werden dabei erkannt und neue IDNs für die weitere Verarbeitung übernommen.



Der aktuelle Bearbeitungsstand wird im Statusfeld angezeigt.



15 neue IDNs übernommen
507 Duplikate entfernt
IDN-Abgleich fertig:
IDN-Abgleich gestartet...

Die gefundenen IDNs werden in der Exceltabelle `DNB_OAI.xlsx` abgelegt
...data\DNB_OAI.xlsx

4. Keyword-Analyse

Mit der **Keyword-Analyse** werden die zuvor ermittelten Inhaltsverzeichnisse anhand definierter Stichwörter untersucht.

In der heruntergeladenen Excel-Datei `data\stichwort.xlsx` sind derzeit beispielhaft die vom DBSM verwendeten Stichwörter hinterlegt.

Wenn Sie das Tool für Ihre eigenen Anforderungen nutzen möchten, können Sie die Stichwortliste **entsprechend Ihrem eigenen Sammlungs- bzw. Arbeitsbereich anpassen, ergänzen oder reduzieren**. Auch die Gewichtungen können dabei individuell festgelegt werden. Siehe Punkt 8 stichwort.xlsx

4.1 Eingabe

Vor dem Start wird die gewünschte **Mindestgesamtwichtung** eingegeben.

A screenshot of a text input field with a light gray border and a light gray background. The number '3' is entered in the field.


Die **Mindestgewichtung** legt fest, welche Treffer für die weitere Verarbeitung berücksichtigt werden.

Für jeden gefundenen Begriff wird die in `stichwort.xlsx` festgelegte **Gewichtung** berücksichtigt. Die Gewichtungen aller gefundenen Stichwörter werden anschließend **addiert**.

Erreicht die daraus entstehende **Gesamtwichtung mindestens den eingestellten Wert**, wird der Datensatz für die weitere Verarbeitung übernommen. Liegt die Gesamtwichtung darunter, wird der Treffer nicht weiter berücksichtigt.

4.2 Verarbeitung starten

Nach Eingabe der Mindestgewichtung wird die Verarbeitung über „**Analyse starten**“ gestartet.

A screenshot of a button with a light gray border and a light gray background. The text 'Analyse starten' is written in a blue font.

Das Programm durchsucht die vorhandenen Inhaltsverzeichnisse im Hintergrund nach den hinterlegten Stichwörtern in `stichwort.xlsx` und bewertet die gefundenen Treffer anhand ihrer Gewichtung. Es werden keine Inhaltsverzeichnisse dafür heruntergeladen. Lediglich der gefundene Wert wird in der Exceltabelle ergänzt.

Nur Datensätze, die die festgelegte Mindestgesamtwichtung erreichen, werden als Ergebnis übernommen.

Der aktuelle Bearbeitungsstand wird im Statusfeld angezeigt.

```
2 Treffer gespeichert
15/15 analysiert
14/15 analysiert
13/15 analysiert
12/15 analysiert
11/15 analysiert
10/15 analysiert
```

Die Ergebnisse werden unter **data/ergebnis.xlsx** mit den Spalten IDN, Stichwörter, Gewichtung und URL gespeichert

A	B	C	D
IDN	Schlagwörter	Gewichtung	URL
1389521141	museum; plakat; typograp	5	https://d-nb.info/1389521141/04/text
1403178364	archiv; archivwesen; bibli	5	https://d-nb.info/1403178364/04/text

IDN ist der Identifier, Stichwörter = die gefundenen Stichwörter aus der stichwort.xlsx, Gewichtung der Wert der gefundenen Stichwörter und URL der Link zum Inhaltsverzeichnis

5. SRU-Schnittstelle


Mit Hilfe der **SRU-Schnittstelle** ruft das Programm anhand der IDN aus der Excel-Tabelle die zugehörigen bibliografischen Datensätze ab und ergänzt die ausgewählten bibliografischen Angaben automatisch in der Excel-Tabelle.

5.1 Auswahlmöglichkeiten

Vor dem Start kann festgelegt werden, welche bibliografischen Angaben über die SRU-Schnittstelle ergänzt werden sollen.

Zur Auswahl stehen:

- Titel
- Zusatztitel
- Autor
- Verlag



A screenshot of a software interface showing four unchecked checkboxes arranged vertically. The labels next to the checkboxes are 'Titel', 'Zusatztitel', 'Autor', and 'Verlag'.

Durch Anklicken der entsprechenden Kontrollkästchen werden die gewünschten Angaben ausgewählt.

Es können mehrere Angaben gleichzeitig ausgewählt werden.

5.2 Verarbeitung starten


Nach Auswahl der gewünschten Angaben wird die Verarbeitung über „**SRU Update starten**“ gestartet.



A screenshot of a button labeled 'SRU Update starten' in a light gray box.

Das Programm ruft die ausgewählten bibliografischen Angaben über die SRU-Schnittstelle ab und ergänzt damit die vorhandenen Datensätze.

Der aktuelle Bearbeitungsstand wird im Statusfeld angezeigt.



A screenshot of a status window titled 'SRU Update'. On the left, it contains a list of instructions: '1. Gewünschte Metadaten auswählen', '2. „SRU Update starten“ anklicken.', and a note that selected data will be retrieved and saved. On the right, there are four checked checkboxes for 'Titel', 'Zusatztitel', 'Autor', and 'Verlag', with the 'Verlag' checkbox highlighted by a dashed border. Below these is the 'SRU Update starten' button. At the bottom, a status field shows the progress: '2 Treffer gespeichert', '15/15 analysiert', '14/15 analysiert', '13/15 analysiert', and '12/15 analysiert'.

```

SRU abgeschlossen: 2 Datensätze
SRU 2/2
SRU 1/2
2 Treffer gespeichert
15/15 analysiert

```

In der Exceltabelle **ergebnis.xlsx** wurden die Daten hinzugefügt:

A	B	C	D	E	F	G	H	I	J
IDN	Schlagwörter	Gewichtung	URL	Titel	Zusatztitel	Autor	Verlag		
138952114	museum;	5	https://d-	Die Lingui	theoretisc	Müller, Al	University of Bamberg Press		
140317836	archiv; arc	5	https://d-	Demokrat	ziviles Engagement		Wallstein Verlag		

6. Statusanzeige

Während der Verarbeitung werden im unteren Bereich des Fensters Statusmeldungen angezeigt.

Die Meldungen informieren darüber, welcher Verarbeitungsschritt gerade ausgeführt wird und ob die Verarbeitung erfolgreich abgeschlossen wurde.

Beispielsweise:


```
Harvest gestartet...
IDN-Abgleich gestartet...
IDN-Abgleich fertig
350 neue IDNs übernommen
```

```
2 Treffer gespeichert
15/15 analysiert
14/15 analysiert
13/15 analysiert
12/15 analysiert
11/15 analysiert
10/15 analysiert
```

Eine Verarbeitung sollte erst dann als abgeschlossen betrachtet werden, wenn im Statusfeld eine entsprechende Abschlussmeldung angezeigt wird.

7. Verarbeitung abbrechen

Eine laufende Verarbeitung kann über die Schaltfläche „STOP“ abgebrochen werden.



Nach dem Anklicken wird eine Abbrucharforderung an die laufende Verarbeitung übermittelt. Der Vorgang wird anschließend beendet.

Der Abbruch wird ebenfalls im Statusfeld angezeigt.

Hinweis: Je nach aktuellem Verarbeitungsschritt kann es etwas dauern, bis die Verarbeitung vollständig beendet ist.

```
0 Treffer gespeichert
6/15 analysiert
Abbruch angefordert
5/15 analysiert
4/15 analysiert
3/15 analysiert
2/15 analysiert
1/15 analysiert
```

8. Ergebnisse

Das Ergebnis finden Sie jeweils unter ...\`data\ergebnis.xlsx`

Bei einer erneuten Verarbeitung werden vorhandene Ergebnisdateien **nicht gelöscht**. Die bisherige Datei wird automatisch in eine **.bak-Datei** umbenannt und bleibt damit als Sicherung erhalten.

Die `.bak`-Datei wird vom Tool **nicht mehr berücksichtigt** und muss bei Bedarf manuell verwaltet bzw. gelöscht werden. Soll eine Sicherungsdatei wieder als reguläre Excel-Datei verwendet werden, kann die Dateiendung **.bak wieder in .xlsx geändert** werden.

9. Dateien

`idn.txt`

Die Datei `idn.txt` enthält die **bereits bekannten IDNs**. Sie dient dazu, bei einem neuen Harvesting bereits verarbeitete Datensätze zu erkennen und nicht erneut zu übernehmen.

Aufbau

In der Datei steht **pro Zeile eine IDN**, zum Beispiel:

```
1031681973
1406932620
1407348000
```

Die Datei wird vom Tool beim IDN-Abgleich eingelesen.

Was passiert beim Harvesting?

Beim Harvesting werden zunächst neue IDNs mit Inhaltsverzeichnis ermittelt. Anschließend kann das Tool diese IDNs mit der vorhandenen `idn.txt` vergleichen.

Dabei werden zwei Gruppen gebildet:

- **bereits vorhandene IDNs** → werden als bereits bekannt erkannt
- **neue IDNs** → werden für die weitere Verarbeitung übernommen

Die neu ermittelten IDNs werden anschließend automatisch in der `idn.txt` ergänzt.

Wichtig: Die `idn.txt` sollte nicht manuell geleert werden, da sie als Grundlage für den Abgleich bereits verarbeiteter Datensätze dient.

stichwort.xlsx

Die Datei `stichwort.xlsx` enthält die **Stichworte, nach denen die Inhaltsverzeichnisse durchsucht werden**.

Sie bildet damit die Grundlage für die Keyword-Analyse.

Aufbau

Die Excel-Datei enthält mindestens die Spalten:

Begriff	Gewichtung
Verlagswesen	3
Codex	2
Verlag	1
Buchgeschichte	3
Biologie	-1

Begriff

In der Spalte „**Begriff**“ werden die Stichworte eingetragen, nach denen in den Inhaltsverzeichnissen gesucht werden soll.

Die Suche erfolgt **nicht ausschließlich nach einer exakten Übereinstimmung**. Für die Stichwortsuche werden reguläre Ausdrücke (Regex) verwendet. Dadurch können auch **Wortstämme und unterschiedliche Wortformen** berücksichtigt werden.

Beispiel:

Wird als Stichwort `Druck` hinterlegt, können damit beispielsweise auch „**Drucker**“, „**Druckerei**“ oder „**Druckverfahren**“ gefunden werden.

Spezifische Begriffe, die eine **höhere Gewichtung** erhalten sollen, müssen zusätzlich als eigenes Stichwort in der Excel-Datei hinterlegt werden.

Beispielsweise:

Begriff	Gewichtung
Druck	1
Druckwesen	3

Wird im Inhaltsverzeichnis „**Druckwesen**“ gefunden, wird der spezifische Begriff „**Druckwesen**“ **mit der Gewichtung 3** berücksichtigt. Dadurch können allgemeine Wortstämme und gleichzeitig spezifische Fachbegriffe gezielt unterschiedlich gewichtet werden.

Gewichtung

Die Spalte „**Gewichtung**“ gibt an, wie aussagekräftig ein Treffer für die Analyse ist.

Als Ausgangspunkt wird eine Gewichtung von **1 bis 3** verwendet:

- **3 – hohe Gewichtung:** Das Stichwort ist sehr aussagekräftig und kann bereits allein auf einen relevanten Inhalt hinweisen.
- **2 – mittlere Gewichtung:** Das Stichwort ist grundsätzlich aussagekräftig, kann aber auch in unterschiedlichen Zusammenhängen vorkommen.
- **1 – niedrige Gewichtung:** Das Stichwort ist weniger eindeutig und sollte möglichst zusammen mit weiteren relevanten Stichworten auftreten.

Die einzelnen Treffer werden bei der Analyse entsprechend ihrer Gewichtung berücksichtigt. Die **Gesamtgewichtung eines Datensatzes** ergibt sich aus den gefundenen Stichworten und deren jeweiligen Gewichtungen.

Hinweis: Die Gewichtung von **1 bis 3 ist lediglich ein Vorschlag** und kann an die jeweiligen Anforderungen angepasst werden. Es können beispielsweise auch Skalen von **1 bis 5** oder **1 bis 10** verwendet werden. In diesem Fall muss lediglich die festgelegte **Mindest-Gesamtgewichtung** entsprechend angepasst werden. Entscheidend ist, dass die gewählte Gewichtung und die Mindest-Gesamtgewichtung zueinander passen.

Es können auch Stichwörter eingetragen werden, die eine negative Gewichtung aufweisen. Dadurch lassen sich eventuell immer wiederkehrende nicht interessante Titel ausgrenzen. Arbeiten sie klassisch mit Minuswerten z.B. -2 oder -1

Anpassung der Stichwortliste

Die Stichwortliste kann an die jeweiligen Anforderungen angepasst und erweitert werden.

Neue Begriffe können ergänzt und bestehende Gewichtungen verändert werden. Dadurch kann die Analyse schrittweise an die gewünschten Ergebnisse angepasst werden.

Hinweis: Änderungen an der Stichwortliste wirken sich direkt auf zukünftige Analysen aus. Die Stichwortliste sollte daher vor einer Analyse geprüft und gegebenenfalls angepasst werden.

10. Logdatei

Unter `\InhaltVZ-Tool\logs` finden Sie die **Logdatei der Anwendung**.

Die Logdatei dokumentiert detailliert, **wann und welche Verarbeitungsschritte** das Programm durchgeführt hat. Darüber hinaus werden dort auch **Fehlermeldungen und aufgetretene Probleme** festgehalten, beispielsweise wenn ein Inhaltsverzeichnis nicht aufgerufen werden konnte.

Die Logdatei wird **fortlaufend ergänzt** und bei einer erneuten Ausführung nicht überschrieben. Dadurch bleibt die Verarbeitungshistorie erhalten.

```
2026-07-16 08:19:11,125 | INFO | infrastructure.http_client | GET https://d-nb.info/481527400/04/text
2026-07-16 08:19:11,359 | INFO | infrastructure.http_client | GET https://d-nb.info/481527362/04/text
2026-07-16 08:19:11,642 | INFO | infrastructure.http_client | GET https://d-nb.info/481527338/04/text
2026-07-16 08:19:11,850 | INFO | infrastructure.http_client | GET https://d-nb.info/481527281/04/text
2026-07-16 08:19:12,195 | INFO | infrastructure.http_client | GET https://d-nb.info/481527168/04/text

2026-07-16 08:21:51,375 | INFO | infrastructure.http_client | GET https://d-nb.info/361764677/04/text
2026-07-16 08:21:51,733 | INFO | core.keyword | Keywordanalyse beendet: 267 Treffer
2026-07-16 08:21:51,746 | INFO | infrastructure.storage | Backup erstellt: C:\Users\sickerti\Projekte\Inhalt_tool\data\ergebnis_20260716_082151.bak
2026-07-16 08:21:51,787 | INFO | infrastructure.storage | Excel gespeichert: C:\Users\sickerti\Projekte\Inhalt_tool\data\ergebnis.xlsx
2026-07-16 08:21:51,788 | INFO | core.keyword_service | Keyword Workflow beendet
2026-07-16 08:22:55,820 | INFO | core.sru_service | SRU Workflow gestartet
2026-07-16 08:22:55,855 | INFO | infrastructure.http_client | GET https://services.dnb.de/openurl?version=1.1&operation=search&uriurn&query_id=140
```